



DERS:

Derin Öğrenme
(FET312)

DÖNEM:

2025-2026 Güz
Dönemi

EKİP ADI:

DeepPark

EKİP ÜYELERİ:

Abdulkadir Gedik – 23040301069

Hamza Hakverir – 20340301096

Yunus Emre Edizer – 20340301042

Muhammet Emin Çapan – 23040301106

GİTHUB LİNKLERİ:

- **Abdulkadir Gedik:**
https://github.com/kkadir8/FET312_DeepPark_Proje.git
- **Muhammet Emin Çapan:**
https://github.com/mcapan2000-boop/FET312_Deep_Park.git
- **Hamza Hakverir:**
<https://github.com/Hamza-Hakverir/Deep-Park.git>
- **Yunus Emre Edizer:**
https://github.com/YunusEdizer/Deep_Park.git

PKLot Veri Seti Kullanılarak Otopark Doluluk Tespiti ve Sınıflandırma Analizi

2 4.11.2025

1. ÖZET (ABSTRACT)

Bu proje, akıllı şehir uygulamaları kapsamında otopark yönetimini otomatize etmek ve verimliliği artırmak amacıyla geliştirilmiştir. Çalışmanın temel hedefi, güvenlik kamerası görüntüleri üzerinden park alanlarının doluluk durumunu (Dolu/Boş) derin öğrenme yöntemleriyle yüksek doğrulukla tespit etmektir. Projede, farklı hava koşullarını (güneşli, bulutlu, yağmurlu) içeren PKLot veri seti (Kaggle varyasyonu) kullanılmıştır. Projenin vize aşaması kapsamında, her grup üyesi tarafından problemi sınıflandırma (classification) düzeyinde ele alan özgün "Base Model" (Temel CNN Mimarisi) yaklaşımları geliştirilmiştir. Bu kapsamda **(1) Temel Referans Model**, **(2) Geniş Filtreli (Wide) CNN**, **(3) Dropout Destekli CNN** ve **(4) Leaky ReLU/AvgPool** mimarileri PyTorch kütüphanesi ile tasarlanmış, eğitilmiş ve performansları karşılaştırılmıştır. Deneysel sonuçlar, tasarlanan sığ (shallow) ağların dahi bu sınıflandırma probleminde %99.80 ile %100 arasında başarımlar gösterdiğini kanıtlamıştır. Raporun sonuç bölümünde, bu modellerin başarımları tartışılmış ve final projesi için planlanan Nesne Algılama (Object Detection) geçiş süreci detaylandırılmıştır.

2. GİRİŞ (INTRODUCTION)

Dünya genelinde artan araç sahipliği, otopark yönetimini kentsel planlamanın en kritik sorunlarından biri haline getirmiştir. Sürücülerin park yeri ararken harcadıkları zaman, şehir içi trafik yoğunluğunu artırmakta ve karbon emisyonuna neden olmaktadır. Geleneksel sensör tabanlı sistemlerin (manyetik veya ultrasonik) kurulum ve bakım maliyetlerinin yüksek olması, görüntü işleme tabanlı merkezi sistemleri cazip hale getirmektedir.

Bu projenin ana amacı, mevcut güvenlik kameralarını kullanarak otopark doluluk durumunu anlık olarak analiz eden, maliyet etkin ve yüksek doğruluklu bir karar destek sistemi geliştirmektir. Proje iki ana fazdan oluşmaktadır:

- Vize Aşaması (Mevcut Durum):** Park yerlerinin kırpılmış (segmented) görüntüleri üzerinden "Dolu" veya "Boş" durumunun ikili sınıflandırılması.
- Final Aşaması (Gelecek Planı):** Tüm otopark görüntüsü üzerinden araçların konumlarının ve durumlarının eş zamanlı tespiti (YOLO, R-CNN).

Bu raporda, vize aşaması kapsamında geliştirilen 4 farklı derin öğrenme yaklaşımı, kullanılan veri ön işleme teknikleri ve deneysel sonuçlar detaylandırılmıştır.

2.1. Veri Seti Özellikleri

Çalışmada, otopark analizi literatüründe standart kabul edilen PKLot veri setinin Kaggle platformunda sunulan versiyonu kullanılmıştır. Veri seti özellikleri şunlardır:

- **Kaynak:** Farklı kampüs otoparklarından alınan, farklı kamera açılara ve ışık koşullarına sahip görüntüler.
- **Veri Büyüklüğü:** Toplam 12.416 adet etiketli görüntü.
- **Sınıf Dağılımı:** Problem ikili sınıflandırma olarak ele alınmış olup, veri seti Space-Occupied (Dolu) ve Space-Empty (Boş) sınıflarından oluşmaktadır.

3. İLGİLİ ÇALIŞMALAR (RELATED WORKS)

Otopark doluluk tespiti üzerine yapılan akademik çalışmalar, geleneksel görüntü işleme tekniklerinden derin öğrenme tabanlı yöntemlere doğru bir evrim geçirmiştir.

Geleneksel Yöntemler: Erken dönem çalışmalarda, park yerlerinin doluluğunu tespit etmek için kenar tespiti, renk histogramları ve doku analizi (LBP - Local Binary Patterns) yöntemleri kullanılmıştır. Almeida ve ark. (2015), PKLot veri setini tanıttıkları çalışmalarında, doku özniteliklerini SVM (Destek Vektör Makineleri) ile sınıflandırarak başarılı sonuçlar elde etmişlerdir. Ancak bu yöntemler, ışık değişimlerinden ve gölgelerden etkilenmektedir.

Derin Öğrenme Yöntemleri: Son yıllarda Evrişimli Sinir Ağları (CNN), öznitelik çıkarımını manuel süreçlerden kurtararak otomatik hale getirmiştir. Amato ve ark. (2017), derin CNN ağlarının (mAlexNet), otopark doluluk tespitinde ışık değişimlerine karşı geleneksel yöntemlerden çok daha dayanıklı olduğunu göstermiştir. Bizim çalışmamız, bu literatürü temel alarak, çok derin olmayan (shallow) ancak iyi tasarlanmış CNN mimarilerinin de bu spesifik problemde yüksek performans gösterebileceğini kanıtlamayı amaçlamaktadır.

4. YÖNTEM (METHODOLOGY)

Bu bölümde, projenin teknik altyapısı, veri ön işleme adımları ve her grup üyesinin geliştirdiği özgün model mimarileri detaylandırılmıştır. Tüm geliştirmeler Python dili ve PyTorch derin öğrenme kütüphanesi kullanılarak yapılmıştır.

4.1. Veri Ön İşleme (Data Preprocessing)

Veri setinin modele verilmeden önce standardize edilmesi, eğitimin stabilitesi için kritiktir. Grup üyeleri tarafından ortak uygulanan adımlar şöyledir:

1. **Yeniden Boyutlandırma (Resizing):** Hesaplama yükünü azaltmak ve CNN giriş katmanına uygun hale getirmek için tüm görüntüler 64x64 piksel boyutuna getirilmiştir.
2. **Tensör Dönüşümü (ToTensor):** Görüntü piksel değerleri [0, 1] aralığına normalize edilmiş ve PyTorch tensör yapısına dönüştürülmüştür.
3. **Veri Ayrımı (Splitting):** Modelin genelleme yeteneğini doğru ölçmek amacıyla veri seti rastgele olarak %80 Eğitim (Training) ve %20 Test setlerine ayrılmıştır. Bu ayırım, modelin eğitim sırasında hiç görmediği verilerle test edilmesini sağlamıştır.

4.2. Temel Model Mimarileri

Grup üyeleri, temel bir CNN iskeleti üzerinde (Konvolüsyon + Havuzlama + Tam Bağlı Katman) anlaşılmış, ancak bu iskeleti farklı teknik hipotezleri test etmek amacıyla özelleştirmişlerdir.

A. Referans Model Yaklaşımı (Geliştiren: Abdulkadir Gedik)

- **Tasarım:** En yalın CNN yapısıdır. 2 adet Conv2d katmanı, her katman sonrasında ReLU aktivasyonu ve 2x2 Max Pooling içerir.
- **Amaç:** Herhangi bir ekstra teknik (dropout, geniş filtre vb.) kullanmadan problemin taban (baseline) başarısını ölçmektir.
- **Konfigürasyon:** Kernel Size: 3x3, Padding: 1.

B. Geniş Filtreli (Wide) CNN Yaklaşımı (Geliştiren: Muhammet Emin Çapan)

- **Tasarım:** İkinci konvolüsyon katmanında standart 3x3 filtre yerine 5x5 boyutunda geniş filtreler kullanılmıştır.
- **Hipotez:** "Receptive Field" (Algılama Alanı) kavramına dayanarak, daha büyük filtrelerin aracın parçasını (far, cam) değil, bütünsel şeklini tek seferde yakalayacağı ve bunun başarıyı artıracığı öngörülmüştür.

C. Regularizasyon Odaklı Yaklaşım (Geliştiren: Hamza Hakverir)

- Tasarım:** Temel modele ek olarak, tam bağlı (Fully Connected) katmanlar öncesine Dropout (0.5) katmanı entegre edilmiştir.
- Hipotez:** Eğitim verisindeki benzer görüntüler modelin ezber yapmasına (overfitting) neden olabilir. Dropout, eğitim sırasında nöronların yarısını rastgele kapatarak ağın daha gürbüz (robust) öznelilikler öğrenmesini sağlar.

D. Aktivasyon ve Havuzlama Varyasyonu (Geliştiren: Yunus Emre Edizer)

- Tasarım:** Standart ReLU yerine LeakyReLU (0.1) ve Max Pooling yerine Average Pooling kullanılmıştır.
- Hipotez:** ReLU fonksiyonundaki "ölü nöron" (negatif değerlerin sıfırlanması) problemini aşmak için sızıntılı (leaky) yapı tercih edilmiştir. Ayrıca, park alanının doluluğunun keskin kenarlardan ziyade "ortalama renk yoğunluğu" ile ilişkili olabileceği düşünülerek Average Pooling test edilmiştir.

5. DENEYLER VE SONUÇLAR (EXPERIMENTS & RESULTS)

Tüm modeller **Adam** optimizasyon algoritması (Learning Rate: 0.001) ve **CrossEntropyLoss** kayıp fonksiyonu kullanılarak 3 epoch boyunca eğitilmiştir.

Elde edilen nihai test sonuçları aşağıdaki tabloda sunulmuştur:

Geliştirici & Model	Mimari Özelliği	Eğitim Kaybı (Final Loss)	Doğruluk (Accuracy)
Abdulkadir Gedik	Temel (Baseline) CNN	0.0037	%99.94
Muhammet Emin Çapan	Wide Kernel (5x5)	0.0062	%100.00
Hamza Hakverir	Dropout (0.5) CNN	0.0045	%99.88
Yunus Emre Edizer	Leaky ReLU + AvgPool	0.0051	%99.90

5.1. Sonuçların Tartışılması

- **Yüksek Başarım:** Tüm modellerin %99 üzerinde performans göstermesi, seçilen PKLot veri setinin kalitesini ve CNN yaklaşımının bu problem için uygunluğunu kanıtlamıştır.
- **Wide CNN Üstünlüğü:** Muhammet Emin Çapan'ın modelinin %100 doğruluğa ulaşması, 5x5 geniş filtrelerin araçların bütünsel yapısını yakalamada, 3x3 filtrelere göre küçük de olsa bir avantaj sağladığını göstermiştir.
- **Regularizasyon Etkisi:** Dropout (Hamza Hakverir) ve Leaky ReLU (Yunus Emre Edizer) kullanan modellerin eğitim kayıplarının çok düşük seviyelerde stabilize olduğu ve ezberleme (overfitting) sorunu yaşamadığı gözlemlenmiştir.

6. SONUÇ VE GELECEK ÇALIŞMALAR (FUTURE WORK)

Bu proje ilerleme raporunda, otopark doluluk tespiti için geliştirilen özgün CNN mimarilerinin başarısı ortaya konulmuştur. Vize aşaması için hedeflenen "Görüntü Sınıflandırma" görevi, basit ama etkili tasarımlarla mükemmel bir doğrulukla tamamlanmıştır.

Projenin Final Aşaması için aşağıdaki yol haritası belirlenmiştir:

1. **Sınıflandırmadan Algılamaya Geçiş:** Mevcut sistem, sadece önceden kırılmış park yeri görüntülerini analiz edebilmektedir. Final projesinde, tüm otopark görüntüsü üzerinde çalışan Nesne Algılama (Object Detection) modellerine geçilecektir.
2. **Gelişmiş Mimarilerin Kullanımı:**
 - **YOLOv8 (You Only Look Once):** Gerçek zamanlı (Real-Time) takip gereksinimi için, hızı ve doğruluğu optimize eden YOLO mimarisi kullanılacaktır.
 - **Faster R-CNN:** Bölge tabanlı (Region-based) bu mimari, özellikle küçük ve uzaktaki araçların tespiti için bir kıyaslama (benchmark) modeli olarak kullanılacaktır.
3. **Video Üzerinde Test:** Sistem, statik görüntülerden çıkarılarak video akışı üzerinde test edilecek ve FPS (Saniye Başına Kare) performansı optimize edilecektir.

7. KAYNAKÇA (REFERENCES)

1. **Veri Seti:** Kaggle Parking Lot Dataset (Blanderbuss/PKLot). Erişim: <https://www.kaggle.com/datasets/blanderbuss/parking-lot-dataset>
2. Almeida, P., Oliveira, L. S., Silva Jr, E., Britto Jr, A., & Koerich, A. (2015). PKLot–A robust dataset for parking lot classification. *Expert Systems with Applications*, 42(11), 4937-4949.
3. Amato, G., Carrara, F., Falchi, F., Gennaro, C., & Vairo, C. (2016). Deep learning for decentralized parking lot occupancy detection. *Expert Systems with Applications*.
4. Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). You only look once: Unified, real-time object detection. *Proceedings of the IEEE conference on computer vision and pattern recognition*.